

دليل تشغيل — تشغيل نموذج عربي جديد خلف الكابتن عادل

القسم operations-it-06 النوع runbook الحالة active المالك Founder آخر تحديث 21-06-2026

يأتي عقل الكابتن عادل (`captadel/`) مزوداً بعدة *خيارات* لنماذج عربية / داخل المملكة — ALLaM (الافتراضي)، Jais, Fanar, Qwen, Command R — لكن كل واحد منها معطل حتى توجهه إلى نقطة نهاية قيد التشغيل. فمن دون تعيين نقطة نهاية، لا يُستخدم المسار العربي إطلاقاً ولا يتغير شيء. يأخذ دليل التشغيل هذا نموذجاً عربياً واحداً من حالة "مدعوم في الشيفرة" إلى حالة "يجب عن أسئلة حقيقية في بيئة الإنتاج"، بأمان.

وهو الدليل المرافق للخانة العربية بجانب `runbook-captain-adel.md` (دالة البوابة) و `deploy/allam-vllm.md` في مستودع captadel (تقديم ALLaM).

نظام حماية البيانات الشخصية (PDPL). أسئلة المستخدمين الحقيقية بيانات شخصية ويجب معالجتها داخل المملكة. استضيف نقطة نهاية النموذج و خدمة captadel في منطقة داخل المملكة العربية السعودية. لا توجه حركة المرور العربية إلى نموذج يُقدّم خارج المملكة.

0. حدّد أي نموذج

راجع `captadel/docs/models.md` للاطلاع على ترتيب الخانة B الكامل. النسخة المختصرة:

- ALLaM-7B — الافتراضي؛ أفضل عربية فصحي حديثة سعودية + أقوى سردية للسيادة. ابدأ من هنا.
- Qwen2.5-14B/32B — إذا كان أتباع ALLaM للتعليمات ضعيفاً جداً؛ الأفضل في الالتزام بعقد الاقتباس فقط؛ ترخيص متساهل.
- Jais / Fanar — بدائل قوية ذات أولوية عربية تستحق التقييم.
- Command R — أفضل سلوك في الاقتباس المُستد، لكنه CC-BY-NC؛ للتقييم فقط ما لم تكن تملك ترخيصاً تجارياً. لا تطرحه على أوزان NC.

تستخدم الخطوات أدناه `<name>` $\ni$ `allam | jais | fanar | qwen | commandr` وبادئة متغيرات البيئة المطابقة `<PREFIX>` (مثل QWEN).

1. قدّم النموذج (vLLM، وحدة معالجة رسومية داخل المملكة)

يعمل أي خادم متوافق مع OpenAI على `/chat/completions` (vLLM أو TGI). باستخدام vLLM:

```
# On a KSA GPU box (A100/H100-class for 13B+; a 7B/9B fits a single 24-48 GB card)
pip install vllm
python -m vllm.entrypoints.openai.api_server \
  --model Qwen/Qwen2.5-14B-Instruct \
  --served-model-name Qwen/Qwen2.5-14B-Instruct \
  --port 8000
# Endpoint is then http://<host>:8000/v1
```

ضعه خلف TLS + رمز مصادقة إذا كان قابلاً للوصول عبر الشبكة. يجب أن يطابق اسم النموذج المُقدّم القيمة `<PREFIX>_MODEL` (القيم الافتراضية في `captadel/.env.example`).

2. اختبار التدخين لنقطة النهاية (≈ 2 ث)

من `captadel/` على أي جهاز يستطيع الوصول إلى نقطة النهاية:

```
QWEN_BASE_URL=http://<host>:8000/v1 QWEN_API_KEY=<token-if-any> \
node evals/provider-smoke.js qwen
```

توقع "PASS ... response: \"pong\"". إذا أخفق فسيخبرك بالسبب (مسار/مضيف خاطئ، عدم تطابق اسم النموذج، رمز مفقود). أصلح المشكلة قبل المتابعة.

3. اجتياز بوابة التكافؤ (هذا هو قرار المضي/عدم المضي الحقيقي)

لا توجه العربية إلى نموذج بناءً على الانطباعات. تشغل البوابة كل حالة تقييم عبر Gemini و المرشح، ولا تنجح إلا إذا طابق المرشح Gemini أو تفوق عليه على المجموعة الفرعية العربية دون تراجع إجمالي:

```
GEMINI_API_KEY=<key> QWEN_BASE_URL=http://<host>:8000/v1 \
node evals/parity.js --provider qwen
```

- الخروج 0 + PARITY OK ← آمن لتوجيه العربية إلى هذا النموذج.
- الخروج 1 + PARITY FAIL ← أبقى MODEL_PROVIDER=gemini؛ جرّب نموذجاً آخر (الخطوة 0) أو حسن الاسترجاع (الخطوة 6) أولاً.

نصيحة: `arabic-only` يركّز التشغيل؛ `tol 1` يسمح بتراجع إجمالي بمقدار حالة واحدة.

4. فعّله على خدمة captadel

عَيّن هذه على خدمة captadel.com (متغيرات بيئة مضيفها / مدير الأسرار — وليس دالة Firebase):

```
QWEN_BASE_URL=http://<host>:8000/v1
QWEN_MODEL=Qwen/Qwen2.5-14B-Instruct      # optional; default in .env.example
QWEN_API_KEY=<token-if-any>                # optional
ARABIC_PROVIDER=qwen                      # make `auto` prefer this Arabic model
MODEL_PROVIDER=auto                       # Arabic-dominant → Arabic model, else Gemini
```

ترك `ARABIC_PROVIDER` غير معيّن يُبقي ALLaM أولاً في ترتيب التفضيل، يبقى المسار الإنجليزي/الوكيلي على Gemini بصرف النظر عن ذلك.

5. النشر + التحقق

انشر خدمة captadel (راجع `runbook-captadel-extraction.md` / `deploy/` للحاوية + الهدف ضمن منطقة داخل المملكة)، ثم:

```
# health
curl https://captadel.com/health      # → { status:"ok", ... }

# an Arabic turn should now answer in Arabic with Latin GACAR citations
curl -XPOST https://captadel.com/v1/chat -H 'Content-Type: application/json' \
-d '{"message":"ما هو الحد الأدنى لسن رخصة الطيار الخاص؟","provider":"auto"}'
```

لا حاجة إلى تغيير الواجهة الأمامية — فإن `chat.html` / البوابة تتحدثان بالفعل عقد `{ message, history, product, provider, session }`. تراجع فوراً بإلغاء تعيين `<PREFIX>_BASE_URL` (أو `MODEL_PROVIDER=gemini`).

6. اختياري — الاسترجاع الهجين (مفتاح التحرر العابر للغات)

مجموعة GACAR في جوهرها إنجليزية، لذا يسترجع سؤال عربي القليل عبر BM25 المعجمي وحده — وسيرفض نموذج عربي (عن حق) الكثير. يصلح الاسترجاع الكثيف متعدد اللغات هذا. وهو معطل افتراضياً؛ فغّله فقط بعد بناء الفهرس:

```
# 1. Serve an embeddings model (BGE-M3) the same OpenAI-compatible way, then
# build the dense index once (writes captadel/src/brain/_embeddings.json.gz):
EMBEDDINGS_BASE_URL=http://<host>:8080/v1  npm run build:embeddings

# 2. Ship the generated _embeddings.json.gz with the service, and set at runtime:
EMBEDDINGS_BASE_URL=http://<host>:8080/v1      # BGE-M3
RERANK_BASE_URL=http://<host>:8081/v1          # optional: bge-reranker-v2-m3
```

مع عدم تعيين أي منهما، يكون الاسترجاع BM25 خالصاً وبلا تغيير. أعد تشغيل بوابة التكافؤ (الخطوة 3) مع تفعيل الهجين — يُفترض أن يقفز الاستدعاء العربي، وأن تجتاز المزيد من الحالات العربية.

قائمة التحقق

- ☐ النموذج مُقدّم في منطقة داخل المملكة، خلف TLS/المصادقة.
- ☐ `PASS ← provider-smoke.js <name>`
- ☐ `PARITY OK ← parity.js --provider <name>` (المجموعة الفرعية العربية).
- ☐ `<PREFIX>_BASE_URL` (+ `MODEL_PROVIDER=auto` , `ARABIC_PROVIDER`) معيّنة على captadel.
- ☐ captadel منشورة في منطقة داخل المملكة؛ `/health` سليمة؛ دور عربي يجب بالعربية مع اقتباسات لاتينية.
- ☐ (اختياري) فهرس التضمينات مبني + `EMBEDDINGS_BASE_URL` معيّن؛ أُعيد فحص التكافؤ.
- ☐ التراجع متحقّق منه: إلغاء تعيين `<PREFIX>_BASE_URL` يعيد إلى Gemini فقط.