

دليل تشغيل — نشر الكابتن عادل (بوابة محادثة RAG)

القسم operations-it-06 النوع runbook الحالة active المالك Founder آخر تحديث 19-08-2026

الكابتن عادل هو الدماغ الكامن خلف `/chat` : يسترجع مقاطع GACAR ويسأل Gemini عن الإجابة، موثقة بالإحالة إلى الجزء/القسم بالضبط. وهو ليس وحدة نشر منفصلة — بل مجموعة مسارات داخل خدمة Express الواحدة على Cloud Run (`/api/chat` و `/api/feedback` ، إضافةً إلى السطح المرخص `/v1/ask`). ونشر الكابتن عادل يعني نشر واجهة API.

[NOTE!] هذه الصفحة تخص الكابتن عادل داخل المنتج (`iflygaca/FlyGACA`). أما الخدمة المستقلة الكامنة خلف `captadel.com` فتقيم في `iflygaca/Captain-Adel` ولها صفحاتها الخاصة `runbook-captadel-*` في هذا المجلد. لا تخط بين الاثنين.

ما تحتاج إليه أولاً

1. مفتاح `Get API key` ← `aistudio.google.com` — Gemini API. يُخزن في Secret Manager باسم `genai-api-key` ويصل إلى الخدمة بوصفه `GOOGLE_GENAI_API_KEY`. ولا يُودع في المستودع أبداً.
2. متن RAG مبنياً داخل الصورة. يعيد `npm run build:chunks` توليد `public/data/rag-chunks.json` وينسخه ملف `Dockerfile` إلى الصورة كي لا يحتاج فهرس BM25 إلى أي جلب عند الإقلاع البارد.
3. خدمة Cloud Run نفسها — مُزوَّدة وفق `docs/RUNBOOK-deploy.md` في `iflygaca/FlyGACA`. ولا دخل لـ Firebase ولا Cloud Functions ولا خطة Blaze في الأمر.

النشر

لا يوجد أمر نشر خاص بالمحادثة. أعد بناء المتن إن تعيّر، ثم انشر واجهة API تمامًا كما يصف دليل التشغيل في مستودع المنتج (`gcloud run deploy`) من جذر المستودع، مع ضبط الأسرار والأسعار على الإصدار).
يعمل `assertRequiredConfig()` قبل أن يرتبط المستمع، فالإصدار الذي ينقصه `DATABASE_URL` أو يحمل `SESSION_SECRET` أقصر ممّا يجب يفشل في فحص سلامته بدل أن يُخطئ بالرمز 500 لاحقاً. ويُعيد `GET /healthz` الرمز 503 حتى تستجيب قاعدة البيانات.
وحالما يصير الإصدار حياً، اطرح سؤالاً عن GACAR على `/chat` — مثلاً `"What are the VFR weather minima?"`. وينبغي أن تحمل الإجابة مصادر ترتبط ارتباطاً عميقاً داخل قارئ المكتبة.

/chat (SPA) —POST /api/chat→ Cloud Run (Express 5)

gateway.ts	quota + rate limits + SSE framing
corpus.ts	BM25 over rag-chunks.json
captain-adel.ts	Genkit → Gemini, cited answer

نقطتا تصميم لهما أثر تشغيلي:

- التأصيل يُحسب من جهة الخادم، لا يُطلب من النموذج. فدون عتبة الرفض لا يُستدعى النموذج إطلاقاً — ويحصل المستخدم على رفض يستشهد بالنظام بدلاً من ذلك. فلا يمكن أن يخرج رقم GACAR ملقّق لمجرّد أن النموذج كان واثقاً.
- خُراس النظام مُختبرون بوحدات اختبار. فقواعد «غير مرتبطة» و«تعليمي فقط» تقيم في وحدتها الخاصة مع اختبار يُفشل البناء إذا أُسقطت إحداها. وهي التوأم الخادمي لإخلاء المسؤولية على مستوى الموقع — عاملها كما تعامل مكوّن إخلاء المسؤولية: لا تُعد صياغتها ارتجالياً.

الضبط والتحكم في التكلفة

الرافعة	المكان	الافتراضي
النموذج (الطبقة المجانية)	Genkit عبر Gemini	gemini-2.5-flash
النموذج (طبقة Pro)	يُختار لكل طلب بحسب خطة المتصل	gemini-2.5-pro
المقاطع المسترجعة	RETRIEVE_K	6
درجة الرفض دونها	REFUSE_SCORE	1.5
درجة التأصيل الكامل	GROUNDED_SCORE	4
الأسئلة المجانية في اليوم	CHAT_FREE_DAILY_LIMIT	5
الأسئلة لكل حزمة أرصدة مشتراة	CHAT_CREDIT_PACK_SIZE	50
مفتاح إيقاف المحادثة	CHAT_ENABLED	true
حدّ الاندفاع لكل حساب	في gateway.ts	20 دورًا/دقيقة
الحدّ العام لكل عنوان IP	في gateway.ts	30 طلبًا/دقيقة
حدّ واجهة API المخصّصة لكل مفتاح	في gateway.ts	60 طلبًا/دقيقة

الحصة اليومية هي أداة التحكم الحقيقية في التكلفة، وهي لكل حساب، في كل يوم — فالطبقة المجانية خمسة أسئلة في اليوم، والنظير من جهة العميل لتلك السياسة مفروض بالاختبارات مقابل نواة الخادم، فلا يمكن أن ينحرف أحدهما عن الآخر. أما محدّدات الاندفاع فذاكرتها لكل نسخة: تحمي من الحلقات المنفلتة وإساءة الاستخدام

العابرة، لا من هجوم موزع.

هو التوقف الاضطراري إذا انفلت إنفاق النموذج. `CHAT_ENABLED=false` g

التحديث لاحقًا

- هل غيّرت المتن؟ `npm run build:chunks` ، وأودع `public/data/rag-chunks.json` القُعاد توليده، وأعد نشر واجهة API.
- هل غيّرت شخصية الكابتن عادل؟ عدّل وحدة الموجه في `server/src/` ، وشغّل مجموعة اختبارات الخادم (سيخبرك اختبار الخُراس إن كنت قد أزلت قاعدة)، ثم أعد النشر.
- هل دوّرت مفتاح Gemini؟ أضف نسخة جديدة إلى السّر `genai-api-key` وانشر إصدارًا جديدًا — إذ تُقرأ الأسرار عند بدء الإصدار.
- هل غيّرت سياسة التسعير أو الحصة؟ نواة الخادم هي مصدر الحقيقة؛ ويُفشل اختبار النظير من جهة العميل في مستودع المنتج البناء إذا حدّثت أحدهما دون الآخر.

استكشاف الأخطاء وإصلاحها

العرض	السبب المرجّح
ترجع المحادثة رفضًا لسؤال تجيب عنه المكتبة بوضوح	جاءت درجة الاسترجاع دون <code>REFUSE_SCORE</code> — تحقّق من إعادة بناء المتن بعد آخر مزامنة محتوى.
كل طلب يُرجع 503	الخدمة تعمل لكن قاعدة البيانات لا تستجيب — <code>/healthz</code> مرهون بها.
<code>429 rate_limited</code>	بلوغ محدّد الاندفاع (20 دويًا/دقيقة لكل حساب). متوقّع تحت جمل مبرمج.
نفاد الحصة لمستخدم مدفوع	افحص سجّل الاستحقاق — فالخطة والأرصدة مملوكة للخادم ولا يكتبها إلا مسارا الفوترة والمنح.
أخطاء نموذج / حصة من Google	حدود Gemini API على مشروع المفتاح. ارفع الحصة أو اخفض حركة المرور.
تصل الإجابات بلا استشهادات	ملف المتن غير موجود في الصورة (<code>CORPUS_URL</code>) — خطوة النسخ في ملف <code>Dockerfile</code> .

تذكيرات ما قبل الإطلاق

- الكابتن عادل ذكاء اصطناعي تعليمي. يقول ذلك إخلاء المسؤولية على الصفحة وخُراس الخادم معًا. أبقِ الاثنين.
- المتن مادة منشورة من الهيئة العامة للطيران المدني فقط. وتقع إشعارات NOTAM والطقس الحيّة خارج النطاق عمدًا، ويرفضها الموجه.
- أكد موقف إعادة توزيع GACAR مع المحامي السعودي (P0-1) قبل الإطلاق العام.